



氢化物超导体临界转变温度的机器学习模型

赵晋彬^{1,2} 王建韬^{2,3} 何东昌^{2,3} 李俊林¹
孙岩² 陈星秋² 刘培涛²

1 太原科技大学 材料科学与工程学院 太原 030024

2 中国科学院金属研究所 沈阳材料科学国家研究中心 沈阳 110016

3 中国科学技术大学 材料科学与工程学院 沈阳 110016

摘要 高压下发现的具有高临界转变温度(T_c)的氢化物超导体激起了研究者对常压室温超导材料探索的广泛兴趣。尽管第一性原理方法可以准确预测氢化物超导体的 T_c ,但电声耦合计算量巨大且十分昂贵,因此迫切需建立一个既准确又高效的 T_c 预测模型。本工作利用随机森林算法,根据特征的重要性选择最关键的特征,开发了一个简单且物理可解释的机器学习模型。该模型利用所选择的4个关键特征(即组成元素价电子数标准差、共价半径平均值和门捷列夫数(Mendeleev数)范围,以及Fermi能级处H的态密度占比)实现了高的 T_c 预测精度(平均绝对误差为24.3 K,均方根误差为33.6 K),这为氢化物超导体的高通量筛选提供了有效预测模型,有助于加速高 T_c 超导氢化物的发现。

关键词 氢化物超导体,超导转变温度,机器学习,随机森林,第一性原理计算

中图分类号 TG132.26

文章编号 0412-1961(2024)10-1418-11

Machine Learning Model for Predicting the Critical Transition Temperature of Hydride Superconductors

ZHAO Jinbin^{1,2}, WANG Jiantao^{2,3}, HE Dongchang^{2,3}, LI Junlin¹,

SUN Yan², CHEN Xing-Qiu², LIU Peitao²

1 School of Materials Science and Engineering, Taiyuan University of Science and Technology,
Taiyuan 030024, China

2 Shenyang National Laboratory for Materials Science, Institute of Metal Research,
Chinese Academy of Sciences, Shenyang 110016, China

3 School of Materials Science and Engineering, University of Science and Technology of China,
Shenyang 110016, China

Correspondent: LIU Peitao, professor, Tel: (024)23971560, E-mail: ptliu@imr.ac.cn

CHEN Xing-Qiu, professor, Tel: (024)23971560, E-mail: xingqiu.chen@imr.ac.cn

Supported by National Natural Science Foundation of China (Nos.52188101 and 52201030), National Key Research and Development Program of China (No.2021YFB3501503), and Key Research Program of Chinese Academy of Sciences (No.ZDRW-CN-2021-2-5)

Manuscript received 2024-05-08, in revised form 2024-07-10

ABSTRACT The discovery of hydride superconductors with high critical transition temperature (T_c) un-

资助项目 国家自然科学基金项目 Nos.52188101 和 52201030, 国家重点研发计划项目 No.2021YFB3501503, 及中国科学院重点部署项目 No.ZDRW-CN-2021-2-5

收稿日期 2024-05-08 **定稿日期** 2024-07-10

作者简介 赵晋彬,男,1991年生,博士生

通讯作者 刘培涛,ptliu@imr.ac.cn,主要从事材料的电子结构计算与原子模拟研究

陈星秋,xingqiu.chen@imr.ac.cn,主要从事合金设计与计算研究

DOI 10.11900/0412.1961.2024.00140

der high pressures has received considerable interest in developing superconducting materials that can operate at room temperature and ambient pressure. Although first-principles methods can accurately predict the critical temperature of hydride superconductors, the computational demands are significant because of the expensive calculation of electron-phonon coupling. Hence, constructing an accurate and efficient model for predicting T_c is highly desirable. In this study, a simple and interpretable machine learning (ML) model was developed using the random forest algorithm, which enables the selection of important features based on their importance. Using four physics-based features, namely, the standard deviation of the number of valence electrons, mean covalent radii, range of the Mendeleev number of constituent elements, and hydrogen fraction of the total density of states at the Fermi energy, the optimal ML model achieves high accuracy, with a mean absolute error of 24.3 K and a root-mean-square error of 33.6 K. The ML model developed in this study shows great application potential for high-throughput screening, thereby expediting the discovery of high- T_c superconducting hydrides.

KEYWORDS hydride superconductor, superconducting transition temperature, machine learning, random forest, first-principles calculation

材料的超导电性一直是凝聚态物理和材料领域的研究热点之一^[1~4]。超导材料的零电阻特性和完美抗磁特性^[5]使得超导体在许多领域具有广阔的应用前景^[3,6],如高效的电力转换、无损的电力输出、超强磁铁、高灵敏度传感器材料等。但是,超导的形成机制依然是理论和实验研究的重大难题之一,尤其是如何突破温度的限制,使得超导体能够在高温(如 ≥ 40 K,BCS (Bardeen-Cooper-Schrieffer)理论预测的极限温度^[7])甚至室温下获得应用,是科学人员一直在攻克的难题。在过去30余年里,科学人员对不能用传统BCS理论^[7]解释的非常规超导体进行了广泛研究。目前,常压下铜基超导体的临界温度(T_c)在20~133 K范围^[8~11],铁基超导体的 T_c 在26~77 K范围^[12~14]。铜基超导体因其 T_c 可以超过77 K(液氮沸点),因此在某些领域获得了应用^[3,6]。近年,镍基超导体^[15~19]成为新的研究热点。Sun等^[16]报道了一种镍氧化物 $\text{La}_3\text{Ni}_2\text{O}_7$ 单晶在14 GPa压力下表现出超导电性,超导转变温度为80 K,是继铜基超导体之后再次在氧化物体系中发现的液氮温区的超导体。然而,由于非常规超导体的形成机制尚不明晰,目前仍存在争议^[20~22],在关于超导转变温度研究上亟待突破。

因此,科研人员将目光转向了可以用理论解释的常规超导体上。但是在传统BCS理论框架下,很难在非氢化物常规超导体的 T_c 上取得突破。例如,目前 T_c 最高的非氢化物常规超导体为 MgB_2 ,常压下测得其 T_c 为39 K^[23]。为寻求更高 T_c 的超导材料,Ashcroft^[24,25]提出以H元素为主要成分的化合物有望实现这个目标。这是因为H是元素周期表中最轻的元素,根据 $T_c \propto 1/\sqrt{M}$ (M 为元素质量),所以氢化物可以实现高的 T_c 。此外,H原子提供了高 T_c 所必要的高频声子以及强的电声耦合作用。在氢化物中通过

其他元素对H原子的化学压缩,可以实现超导的临界压力降低^[24,25]。需要强调的是,氢化物超导体是唯一先通过理论预测、后被实验验证的超导材料。其中2个最为典型的例子为氢化物超导体 H_3S ^[26~28]和 LaH_{10} ^[29~31]。这重新激发了研究者对寻找高 T_c 超导体的浓厚兴趣^[32,33]。随着超导理论的完善和计算能力的提升,许多氢化物超导体体系被理论预测并在实验中成功合成,如Y-H^[34,35]、Th-H^[36,37]、Ce-H^[38,39]、Ca-H^[40,41]等体系。

尽管如此,对氢化物超导体的研究仍面临着一些问题和挑战。例如,目前发现的大多数氢化物超导体都需要在高压条件下才能稳定存在,而且电声耦合的强度也依赖于高压。为了降低所需要的压力,研究者将重心转向三元或多元氢化物上,因为它们具有进一步提高 T_c 并降低金属化压强的潜力^[42~51]。目前理论预测的最高 T_c 的氢化物超导材料为Sun等^[43]预测的 $\text{Li}_2\text{MgH}_{16}$,250 GPa下 T_c 高达473 K。目前已预测了一些可以在中低压区实现高 T_c 的氢化物超导材料。如,Gao等^[52]预测 KB_2H_8 在12 GPa下 T_c 为134~146 K^[52]。Zhang等^[53]预测了一系列具有萤石型结构框架的 AXH_8 ($A = \text{Sc}, \text{Ca}, \text{Y}, \text{Sr}, \text{La}, \text{Ba}, X = \text{Be}, \text{B}, \text{Al}$)氢化物超导体,其中 LaBeH_8 被预测在20 GPa下可以声子稳定,预测 T_c 约为185 K^[53]。之后不久, LaBeH_8 被Song等^[54]首次在实验上成功合成,在80 GPa下测得的 T_c 为110 K。Zhao等^[55]研究了Y-Ca-H的体系结构和超导性,发现了4种笼型结构三元氢化物,经过计算, $\text{Y}_3\text{CaH}_{24}$ 的超导转变温度在150 GPa下为242~258 K^[55]。Du等^[56]通过将重稀土元素Yb/Lu加入类钠盐的六氢化物中,得到一系列可以在中压下稳定的高 T_c 氢化物超导体,其中 $\text{Y}_3\text{LuH}_{24}$ 在120 GPa下 T_c 为283 K, YLuH_{12} 在140 GPa下 T_c 为275 K, $\text{YLu}_3\text{H}_{24}$ 在110 GPa下 T_c 为288 K。最近,Sanna等^[57]

理论预测了 Mg_2XH_6 ($X = \text{Rh}, \text{Ir}, \text{Pd}, \text{Pt}$) 常压超导家族, 预测的常压下超导转变温度在 45~80 K 之间。同时期内, Dolui 等^[58]也独立地理论预测 Mg_2IrH_6 为常压超导材料, 并提出了可能的实验合成路径。此外, 一些学者对高 T_c 的成因进行了相关性研究。比如 Belli 等^[59]利用第一性原理计算分析了 100 多种二元氢化物超导体的电子和结构特性, 发现 T_c 与电子键合之间存在很强的相关性, 并建立了一个基于电子局域函数网络的描述符来预测 T_c 。Liu 等^[60]提出了实现高 T_c 氢化物超导的 2 种规则(即最优价电子数规则和最优原子占据规则), 并在此基础上预测了 CaHfH_{12} 在 300 GPa 下 T_c 为 360 K, CaZrH_{12} 在 200 GPa 下 T_c 为 290 K。

综上氢化物超导材料的研究发展可见理论预测的重要性。第一性原理方法(如 Eliashberg 理论^[61,62]、McMillan-Allen-Dynes 公式^[63-65]及超导密度泛函理论^[66-68])可以准确预测氢化物超导体的 T_c , 但计算量很大。尤其是在强电声耦合超导体^[69]中, 电声耦合矩阵计算十分昂贵。因此, 开发准确且高效的氢化物超导转变温度预测模型是十分必要的。随着数据库和人工智能方法的快速发展, 数据驱动和机器学习方法也逐渐被应用于超导领域。

在数据驱动方面, Shipley 等^[70]利用晶体结构预测方法搜索了整个元素周期表 10~50 GPa 下稳定的二元氢化物, 对最佳超导候选材料进行了高通量计算, 发现了 36 种 T_c 超过 100 K 的声子稳定的高压氢化物超导体。Choudhary 和 Garrity^[69]针对常规超导体开发了一个高通量计算 workflow, 计算了超过 1000 个材料的 T_c , 建立了一个系统的 BCS 超导数据库, 并基于此开发了深度学习预测模型。Saha 等^[71]基于现有氢化物超导体的结构框架, 通过元素替换方式获得了 139 个新的氢化物超导体, 并基于此创建了 Superhydra 数据库, 目前仅限于在 200 GPa 下的二元氢化物。Sommer 等^[72]建立了“3DSC”超导数据库, 其中包括 T_c 和结构数据, 以便进行机器学习。Cerqueira 等^[73]对 7000 多个常规超导候选材料的 T_c 进行了高通量第一性原理计算, 发现了许多之前尚未报道的新超导材料。

在机器学习预测方面, Stanev 等^[74]使用随机森林(random forest, RF)机器学习方法^[75]对 SuperCon 数据库^[76]中超过 12000 条的超导数据进行了训练, 探索了超导电性与材料化学/结构特性之间的联系。Hutcheon 等^[77]针对二元氢化物 EH_n (其中 E 为除 H 元素以外的其他元素, 如 La、Mg 等), 将 E 元素的 van der Waals 半径、原子序数、原子质量、原子每个轨道

上的电子数及 H 含量作为描述符, 构建了一个基于神经网络的机器学习模型, 模型均方根误差为 34 K。Liu 等^[78]对轨道属性、电子壳层信息等具有物理意义的特征进行了排列组合, 得到了 140 多个特征, 对 SuperCon 数据库的 T_c 数据进行了回归预测, 得出材料的超导转变温度上限与电子轨道杂化存在着很强的联系。Wines 和 Choudhary^[79]使用第一性原理计算预测了 900 多种氢化物材料的 T_c , 发现了 125 种稳定的结构, 并开发了图神经网络 T_c 预测模型, 大大缩减了预测成本。

需要注意的是, 上述工作都是利用大量的特征, 通过强相关方法对超导转变温度进行拟合和预测。尽管发现了一些关联规律, 但是过多的特征会增加模型的复杂度并降低模型的物理可解释性。本工作围绕已被理论预测或被实验证实的氢化物超导体, 利用随机森林算法, 开发了一个简单且物理可解释的 T_c 机器学习预测模型。随机森林算法可对特征按重要性进行排序, 从而选取出最关键的特征, 不仅可以降低模型过拟合的风险, 同时可以增加模型的可解释性和泛化能力。结果发现, 仅基于所选择的 4 个最关键的且具有物理意义的特征(包含组成元素的价电子数的标准差、共价半径的平均值和门捷列夫数(Mendeleev 数)的范围, 以及 Fermi 能级处 H 的态密度占比), 所构建的机器学习模型便可以实现较高的 T_c 预测精度(平均绝对误差为 24.3 K, 均方根误差为 33.6 K)。本工作开发的 T_c 机器学习模型和公式为氢化物超导体的高通量筛选提供了有效预测模型, 进而有助于加速高 T_c 超导氢化物的发现。

1 计算方法

1.1 数据收集

本工作从文献中收集了 258 个 T_c 大于 10 K 的氢化物超导体, 包含对应的压强和结构数据, 详细数据汇总在补充材料表 S1 中。这是目前收集的较为齐全的氢化物超导体数据集。本工作仅聚焦氢化物超导体, 这是因为氢化物超导体具有较高 T_c 的潜质, 而且可以用理论来预测其 T_c , 理论预测数据多且较为干净, 便于机器学习。所收集的氢化物超导体包含二元和三元氢化物, 其数据分布见图 1。可见, 大多数氢化物超导体都需要一个很高的压力来实现超导电性。从 T_c 与压强的关系分布图(图 1a)可以看出, 三元氢化物超导体大都在二元氢化物超导体的左上方, 意味着在相同 T_c 下三元氢化物超导体需要的临界压力相对较低, 或者在相同压力下三元氢化物超导体表现出较高的 T_c 。这正是目前研究者把研究重




图1 氢化物超导体的分布情况
Fig.1 Distribution of hydride superconductors
(a) critical temperature (T_c) vs pressure
(b) number of binary and ternary hydrides in different T_c distribution intervals

心转到三元或多元氢化物的原因。从不同 T_c 分布区间的二元和三元氢化物的数量对比(图1b)可见,相比二元氢化物,三元氢化物超导体的数量较少,约占二元氢化物超导体的 1/5,这意味着有更多的三元或多元氢化物超导体仍未被探索。

1.2 特征获取

为了建立准确、可靠的机器学习模型,选取相关的重要特征是极为必要的。考虑的特征不仅应该能够唯一地表示每种材料,还应该容易计算,以便对新材料进行快速预测。本工作获取特征的方式有3种。第一,使用 MATMINER 软件包^[80]获取。该软件包是一个很好的资源库,可以快速地生成特征,特别适用材料科学领域。同时,下载了材料的一系列广谱特征,如共价半径、原子质量、价电子数、配位数、Mendeleev 数等。此外,还捕获了构成元素的 s、p、d、f 壳层中价电子的平均数量。第二,针对收集的氢化物超导体的晶体结构进行键长和配位数的计算,得到了键长(最短、最长及平均)和配位数特征。第三,引入具有物理意义的特征。受 Belli 等^[59]和 Liu 等^[78]工作的启发,本工作通过第一性原理计算得到最高

饱和轨道和最低不饱和轨道之间的能级间隔 ΔE ^[78]、Fermi 能级处体系的总态密度(TDOS)、Fermi 能级处 H 的态密度占比(HDOS Fraction)、氢化物中 H 原子的原子比例(H_d)等。通过这3种方式,本工作最终获得了共计 133 个特征。

1.3 第一性原理计算

使用基于密度泛函理论的 VASP^[81,82]软件计算电子态密度和 ΔE 。选用广义梯度近似下的 Perdew-Burke-Ernzerhof (PBE)^[83]电子交换关联泛函。平面波截断能设置为 600 eV。结构优化和态密度计算分别使用了波矢 k 点间距为 $0.3 \times 2\pi \text{ nm}^{-1}$ 和 $0.2 \times 2\pi \text{ nm}^{-1}$ 的格点。 ΔE 的具体计算公式如下^[78]:

$$\Delta E = \frac{n_1 \sum E_1 \cdot \text{PDOS}(E_1)}{\sum \text{DOS}(E_1)} - \frac{n_2 \sum E_2 \cdot \text{PDOS}(E_2)}{\sum \text{DOS}(E_2)} \tag{1}$$

式中, E_1 代表氢化物中某一原子的最高占据轨道能量, E_2 表示 H 原子的 s 轨道能量; PDOS 和 DOS 分别为各原子的轨道分辨投影态密度和总的态密度; n_1 和 n_2 表示原子个数。利用了 vaspkit 软件^[84]提取了 VASP 计算的态密度信息,然后进行了更密格点的插值。

1.4 机器学习模型与训练

本工作主要使用 SCIKIT-LEARN (sklearn)库^[85]提供的随机森林算法。随机森林算法是一种基于决策树的集成学习算法,不论是在分类还是在回归方面都表现出良好的性能。它的优点是计算量小,适用于较少数据集的机器学习。最重要的是,随机森林算法可以评估每个特征对目标变量的重要性,这对关键特征筛选、提高机器学习模型泛化能力非常有用。本工作所用随机森林算法的超参数见表1。其中, n-estimators 决定决策树的数量,增加树的数量可

表1 随机森林算法在 sklearn 库中使用的超参数(其他未明确指出的参数使用了默认值)

Table 1 Hyper-parameters used in the sklearn library for the random forest algorithm (For other parameters that are not explicitly specified, default values are used)

Parameter	Meaning of parameter	Value
n-estimators	Number of decision trees	10-30
Max-depth	Maximum depth of decision trees	None, 1, 2, 4
Min-samples-split	Minimum number of samples required to split internal nodes	2, 4, 8
Min-samples-leaf	Minimum number of samples at leaf nodes	1, 2, 4, 8

以提高模型的准确性和稳定性,但同时也会增加计算成本和过拟合风险。 max-depth 为决策树的最大深度,限制树的最大深度可以防止过拟合,但也可能导致欠拟合,如果没有特别指定,树会一直生长直到叶节点都是纯叶节点或者达到 max-depth 指定的最大深度。 min-samples-split 为分割内部节点所需的最小样本数,增加这个值可以使得树更加平滑,减少过拟合风险,但是可能导致模型变得过于简单。 min-samples-leaf 为叶节点最小样本数,这个参数控制着树的复杂度,增加它的值可以使模型更加稳定,但可能导致过拟合。

针对关键特征筛选,首先利用递归特征消除算法,将特征数量从初始的 133 个减少至 55 个。随后进行第二次递归特征消除计算,将 55 个特征再次降低至 11 个。这 11 个特征分别是:Fermi 能级处的 TDOS、Fermi 能级处的 HDOS Fraction、平均键长 [Mean(length)]、平均配位数 [Mean(cu)]、3 个 Mendeleev 数特征 [Mean(Mendeleev Number)、Range (Mendeleev Number) 及 Min(Mendeleev Number)]、平均族序数 [Mean(column)]、平均共价半径 [Mean(CovalentRadius)]、最小电负性 [Min(Electronegativity)]、及价电子数的标准差 [Avg_dev(NValence)]。需要指出的是,Liu 等^[78]提出的 ΔE 因其重要性值较低而未保留下来。这说明尽管 ΔE 与超导材料 T_c 的上限存在很强的相关性^[78],但是 ΔE 对 T_c 本身并不是一个重要的特征。

接下来,使用随机森林方法进行回归训练,按照重要性对特征进行排序及分析。在每一轮训练中,将特征进行重新组合,比如从 11 个特征中筛选出 10 个,一共有 11 种组合,然后选择其中测试误差最低的一组,再进行下一轮回归训练,直至在特征数量尽可能少的前提下训练的模型足够准确。

2 计算结果

对于特征的筛选过程,在每次随机森林训练结束时,剔除重要性最低的特征,并重新评估模型的精度。常用的精度评估方法包括平均绝对误差(MAE)和均方根误差(RMSE)。在特征数量递归降低过程中,固定训练集的比例为 90%,其余 10% 的数据作为测试集。模型测试误差与特征数量的关系见图 2a。可见,模型在特征数量为 4 时表现最好,测试集误差为 $\text{MAE} = 24.3 \text{ K}$, $\text{RMSE} = 33.6 \text{ K}$ 。

为了消除模型的偶然性并验证筛选出的 4 个特征是否是理想结果,利用这 4 个特征进行了第二项计算实验,即通过改变训练集的分布方式和训练集




图2 单次训练下临界温度(T_c)的模型测试误差与特征数量的关系,及 10 次独立训练下的平均模型测试集误差与训练集占比的关系

Fig.2 Model test errors as a function of number of features for one single training (a) and averaged model test errors of ten independent trainings as a function of training set ratio (b) (The shadow-filled areas show the standard deviation. MAE—mean absolute error, RMSE—root mean square error)

与测试集的占比来验证模型的稳定性。首先,在划分训练集和测试集的时候,使用 sklearn 库中的 `train_test_split` 函数,并对随机种子 `random_state` 进行修改。`random_state` 通常用于控制随机数生产过程,使用相同的 `random_state` 值时会得到完全相同的训练集/测试集划分,这样会导致模型在测试集上的表现过于理想。因此,更改 `random_state` 值获取不同的训练集/测试集随机划分来验证模型的准确性是非常有必要的。本工作中,一共进行了 10 次修改(`random_state = 10~100`, 间隔为 10),取 10 次结果的平均值作为最终的模型测试结果,标准差作为误差区间。10 次独立训练下的平均模型测试集误差与训练集占比的关系见图 2b。可见,随着训练集占比的提高,模型的精度会越来越好,但是当训练集占比过高时则会出现模型过拟合,导致模型测试集误差增大。在训练过程中,使用 sklearn 库中的 `GridSearchCV` 模块进行了参数搜索。`GridSearchCV` 模块可以自动调参,其遍历所有可能参数组合,最终确

定最优结果对应的组合参数。GridSearchCV 模块里内置了交叉验证功能,本工作使用了五倍交叉验证($cv = 5$)进行模型训练。需要指出的是,本工作也尝试了使用十倍交叉验证进行模型训练,最后发现其与五倍交叉验证相比,模型精度不受影响。通过对数据集进行十次划分,再结合五倍交叉验证的模型训练,大大消除了模型训练结果的偶然性。发现当训练集占比为90%时,模型测试集 MAE 和 RMSE 的均值最低,即 $MAE = (38.6 \pm 7.8) \text{ K}$, $RMSE = (56.2 \pm 14.3) \text{ K}$ 。

图 3a 给出了递归筛选出的最重要的 4 个特




图3 递归筛选出的最重要的4个特征,及所获得的最精确的机器学习模型预测的 T_c 与真值对比

Fig.3 The most important 4 features by recursive selections (a) and T_c predicted by the most accurate machine learning model obtained vs the ground-truth values (b) ([Avg_dev(NValence)]—standard deviation of the number of valence electrons of constituent element, [Mean(CovalentRadius)]—mean covalent radius of constituent element, [Range(Mendeleev Number)]—range of the Mendeleev number of constituent element, HDOS Fraction—hydrogen fraction of the total density of states at the Fermi energy)

征及其重要性值。按照重要性增加的顺序排序为: [Mean(CovalentRadius)], [Avg_dev(NValence)], [Range(Mendeleev Number)]及(HDOS Fraction)。图 3b 给出了基于这 4 个关键特征训练获得的最精确的机器学习模型(使用训练集占比 0.9 和 $n_{\text{estimators}} = 29$ 获得)预测的 T_c 与真值对比。可见,预测的训练集和测试集的 T_c 大多集中在 $y = x$ 两侧,因此不存在严重的模型过拟合问题。模型测试集误差为: $MAE = 24.3 \text{ K}$, $RMSE = 33.6 \text{ K}$ 。需要强调的是,在这 4 个关键特征的基础上减少特征数量或添加其他的特征都会降低模型的精度(图 2a)。

3 分析讨论

下文重点分析这 4 个特征并探讨它们与 T_c 的关系。

3.1 价电子数(NValence)

Stanev 等^[74]曾在自己的工作提到“3 个‘黄金描述符’将 60 个已知的 $T_c > 10 \text{ K}$ 的超导体限制在了特征空间的 3 个小岛上:平均价电子数、轨道半径差和金属电负性差”。选择这 3 个描述符是因为它们在二元、三元化合物的分类上以及稳态、亚稳态晶体的预测方面获得的成功^[74]。Liu 等^[60]发现在金属氢化物超导体中,要使金属原子为 H 原子有效提供电子,那么金属原子应该具有价电子数 3。由此可见,价电子数对氢化物超导是一个重要的特征。而在本工作开发的氢化物超导体 T_c 机器学习预测模型中, [Avg_dev(NValence)] 被随机森林算法选为一个重要的特征。从图 4a 可以看出,高 T_c 氢化物超导体大多集中在 $\text{Avg_dev(NValence)} = 0 \sim 1$ 的区域内。此外,通过绘制 T_c 与金属氢化物超导体中金属原子价电子数平均值的关系图,发现高 T_c 金属氢化物超导体大都分布在金属原子价电子数平均值为 3 的区域,这与 Liu 等^[60]发现的最优价电子数规则高度一致。

3.2 平均原子半径(Mean CovalentRadius)

原子半径影响原子间的距离和相互作用强度,从而影响晶体结构和电子结构。对超导材料来说,晶体结构的变化会影响其中电子的相互作用方式,从而影响电子的运动和配对。在金属氢化物超导体中为了实现高的 T_c ,需要对 H 原子施加尽可能高的化学挤压,那么金属元素的原子半径需要在给定的晶格下使金属原子最大地填充晶格。这就是 Liu 等^[60]提出的最优原子占据规则。此外,在 Stanev 等^[74]和 Hutcheon 等^[77]开发的机器学习模型中,平均原子半径亦作为一个重要的特征。图 4b 绘制了 T_c 与平均共价半径的关系。可见,高 T_c 氢化物超导体的平均共价半径一般在 $40 \sim 55 \text{ pm}$ 范围内。




图4 T_c 与组成元素的价电子数的标准差、平均共价半径、Mendelev 数范围, 及 Fermi 能级处 H 的电子态密度占比 4 个特征的相关性

Fig.4 Correlation between T_c and four features of Avg_dev(NValence) (a), Mean(CovalentRadius) (b), Range(Mendelev Number) (c), and HDOS Fraction (d)

3.3 Mendelev 数(Mendelev Number, MN)

Mendelev 数由 Pettifor^[86,87] 在 1984 年首次提出, 是晶体中每个化学元素分配的排列数, 目的是使具有相似行为的化学元素归为一类^[86,88]。在 Pettifor 图中, 元素被排列成一条线或曲线, 这条线上的元素按照它们的化合物形成能力进行排序。Pettifor 图中位置接近的元素通常意味着具有相似的化合物形成能力。元素的电负性和原子半径也是排列元素时考虑的因素之一, 这些物理化学性质影响元素之间的相互作用, 从而影响化合物的形成和性质。换句话说, MN 根据元素的电子结构和化学性质改变元素的顺序, 使具有相似性质的元素彼此靠近。

在金属氢化物超导体中, Range(Mendelev Number) 表示氢化物中元素 MN 最大的数(即 H 的 MN 数 92)减去元素 MN 最小的数。图 4c 展示了 T_c 与 Range(Mendelev Number) 的关系。从图中的趋势可以看出, MN 较小的金属元素有助于提高氢化物超导体的 T_c 。这是因为 MN 较小的金属元素通常

具有较低的电负性、较大的原子半径及较低的价电子数, 如 Y、La 等元素。这些金属元素可能更容易与 H 元素形成超氢化物, 有助于提高 T_c 。这与文献[34, 35, 53, 54]报道的高 T_c 氢化物超导体大都是钇或镧基超氢化物相一致。

3.4 Fermi 能级处 H 的电子态密度占比(HDOS Fraction)

Fermi 能级处电子的态密度 $D(E_f)$ 对 T_c 的影响体现在简化的 BCS 公式^[7]中:

$$T_c \propto \exp\left(-\frac{1}{\lambda \cdot D(E_f)}\right) \quad (2)$$

式中, λ 是电声耦合系数。但是, Belli 等^[59]发现在部分氢化物超导材料中, T_c 与体系总的电子态密度似乎没有太大的关联。与之相比, 他们发现与 T_c 相关性更强的是 H_{DOS} ^[59]。从图 4d 中可以看出, T_c 确实与 H_{DOS} 存在着很强的正相关性, 即 H_{DOS} 越大, T_c 通常也越高。这也与本工作中通过随机森林算法获得的特征重要性评价一致, 表现出 H_{DOS} 特征的重要性值最高(图 3a)。需要强调的是, H_{DOS} 特征也蕴含了压强的

信息。即随着压强的改变,材料的结构与 DOS 也随之变化。尽管 T_c 与压强的关系十分密切,但是在机器学习过程中,压强特征因重要性低而被筛选掉,而 H_{DOS} 特征则因为具有更高的重要性而被保留下来。基于 H_{DOS} , Belli 等提出了一个预测 T_c 的经验公式^[59]:

$$T_c = (750\varphi H_{\text{f}}^3 \sqrt{H_{\text{DOS}}} - 85) \quad (3)$$

式中, φ 是电子局域函数网络的描述符, H_{f} 为 H 在氢化物中的原子分数。该经验公式是通过拟合 178 种超导材料(包含纯 H 和二元氢化物)获得的, 预测精度约为 60 K^[59]。

3.5 模型比较


为了比较构建的随机森林机器学习预测模型和

表 2 针对数据集中 6 个 T_c 最高的氢化物超导材料的模型预测^[43,59,60,70,89]

Table 2 Model predictions for the six hydride superconductors with the highest T_c in the dataset^[43,59,60,70,89]

Material	Pressure GPa	H_{DOS}	Range (Mendelev Number)	Mean (CovalentRadius)	Avg_dev (NValence)	T_c (RF) K	T_c (Belli) ^[59] K	T_c (Expt.) K
Li ₂ MgH ₁₆	250	0.53	91	47.0	0.10	319.3	298.3	473.0 ^[43]
CaHfH ₁₂	190	0.28	85	51.6	2.24	324.9	198.3	363.0 ^[60]
CaHfH ₁₈	300	0.41	85	45.5	1.62	339.0	332.0	345.0 ^[60]
CaZrH ₁₂	300	0.31	85	51.6	0.49	308.2	192.6	343.0 ^[60]
MgH ₁₂	500	0.72	24	39.5	0.14	300.5	522.4	340.0 ^[70]
YH ₁₀	250	0.41	80	45.6	0.33	312.5	259.6	326.0 ^[89]
MAE	—	—	—	—	—	47.6	125.3	—
RMSE	—	—	—	—	—	68.4	140.3	—

Note: RF—random forest, H_{DOS} —hydrogen fraction of the total density of states at the Fermi energy



Color online

图 5 数据集中 6 个 T_c 最高的氢化物超导材料的晶体结构和电子态密度

Fig.5 Crystal structures and electronic densities of states for the six hydride superconductors with the highest T_c in the dataset

(a) Li₂MgH₁₆ (250 GPa) (b) CaHfH₁₂ (190 GPa) (c) CaHfH₁₈ (300 GPa)
(d) CaZrH₁₂ (300 GPa) (e) MgH₁₂ (500 GPa) (f) YH₁₀ (250 GPa)

Belli 等^[59]提出的经验公式(3),作为例子,本工作仅针对数据集中 6 个 T_c 最高的氢化物超导材料的 T_c 进行了预测,具体对比结果见表 2^[43,59,60,70,89]。它们的晶体结构和电子态密度见图 5。可见,随机森林机器学习预测模型最优,其性能要远优于 Belli 经验公式(3)。从表 2^[43,59,60,70,89]也可以看到,高 T_c 氢化物超导体一般具有高的 H_{DOS} 或 Range(MN)。图 5 表明,6 个 T_c 最高的氢化物超导材料都是具有笼型结构的超氢化物。

4 结论

针对金属氢化物超导体的临界转变温度,本工作建立了一个简单、准确且物理可解释的随机森林机器学习预测模型。这得益于收集的数据集比较丰富全面,引入了具有物理意义的特征,以及充分运用了随机森林算法具有的特征重要性评估的特性。所构建的模型仅仅基于 4 个关键特征,即组成元素价电子数的标准差、共价半径的平均值和 Mendeleev 数范围,以及 Fermi 能级处 H 的电子态密度占比,便实现了测试集平均绝对误差为 24.3 K、均方根误差为 33.6 K 高的模型预测精度。此外,通过深入分析这 4 个特征与超导临界转变温度的关系,发现高 T_c 金属氢化物超导体一般具有如下特性:(1) 金属元素的价电子数平均值为 3,价电子数的标准差在 0~1 范围内;(2) 组成元素的平均共价半径在 40~55 pm 范围内;(3) 金属元素具有较小的 Mendeleev 数;(4) Fermi 能级处具有较高的 H 的电子态密度占比。

文中补充材料可通过以下网址查看: <https://www.ams.org.cn/CN/10.11900/0412.1961.2024.00140>

参 考 文 献

- [1] De Nobel J, Lindenfeld P. The discovery of superconductivity [J]. Phys. Today, 1996, 49: 40
- [2] Boeri L, Hennig R, Hirschfeld P, et al. The 2021 room-temperature superconductivity roadmap [J]. J. Phys. Condens. Matter, 2022, 34: 183002
- [3] Kim C J. Superconductor Levitation: Concepts and Experiments [M]. Singapore: Springer, 2019: 1
- [4] Mangin P, Kahn R. Superconductivity: An introduction [M]. Cham: Springer, 2017: 1
- [5] Meissner W, Ochsenfeld R. Ein neuer effekt bei eintritt der supra-leitfähigkeit [J]. Naturwissenschaften, 1933, 21: 787
- [6] Hirsch J E, Maple M B, Marsiglio F. Superconducting materials classes: Introduction and overview [J]. Physica, 2015, 514C: 1
- [7] Bardeen J, Cooper L N, Schrieffer J R. Microscopic theory of superconductivity [J]. Phys. Rev., 1957, 106: 162
- [8] Bednorz J G, Müller K A. Possible high T_c superconductivity in the Ba-La-Cu-O system [J]. Z. Phys., 1986, 64B: 189
- [9] Keimer B, Kivelson S A, Norman M R, et al. From quantum matter to high-temperature superconductivity in copper oxides [J]. Nature, 2015, 518: 179
- [10] Wu M K, Ashburn J R, Torng C J, et al. Superconductivity at 93 K in a new mixed-phase Y-Ba-Cu-O compound system at ambient pressure [J]. Phys. Rev. Lett., 1987, 58: 908
- [11] Schilling A, Cantoni M, Guo J D, et al. Superconductivity above 130 K in the Hg-Ba-Ca-Cu-O system [J]. Nature, 1993, 363: 56
- [12] Kamihara Y, Watanabe T, Hirano M, et al. Iron-based layered superconductor $\text{La}[\text{O}_{1-x}\text{F}_x]\text{FeAs}$ ($x = 0.05-0.12$) with $T_c = 26$ K [J]. J. Am. Chem. Soc., 2008, 130: 3296
- [13] Paglione J, Greene R L. High-temperature superconductivity in iron-based materials [J]. Nat. Phys., 2010, 6: 645
- [14] Wang Q Y, Li Z, Zhang W H, et al. Interface-induced high-temperature superconductivity in single unit-cell FeSe films on SrTiO_3 [J]. Chin. Phys. Lett., 2012, 29: 037402
- [15] Li D F, Lee K, Wang B Y, et al. Superconductivity in an infinite-layer nickelate [J]. Nature, 2019, 572: 624
- [16] Sun H L, Huo M W, Hu X W, et al. Signatures of superconductivity near 80 K in a nickelate under high pressure [J]. Nature, 2023, 621: 493
- [17] Li Q, Zhang Y J, Xiang Z N, et al. Signature of superconductivity in pressurized $\text{La}_4\text{Ni}_3\text{O}_{10}$ [J]. Chin. Phys. Lett., 2024, 41: 017401
- [18] Zhang M X, Pei C Y, Du X, et al. Superconductivity in trilayer nickelate $\text{La}_4\text{Ni}_3\text{O}_{10}$ under pressure [DB/OL]. arXiv: 2311.07423, 2023
- [19] Wang M. Discovery of high- T_c superconductivity in a nickelate [J]. Physics, 2023, 52: 663
(王 猛. 液氮温区镍氧化物高温超导体的发现 [J]. 物理, 2023, 52: 663)
- [20] Pickett W E. Colloquium: Room temperature superconductivity: The roles of theory and materials design [J]. Rev. Mod. Phys., 2023, 95: 021001
- [21] Hu J P. Searching for new unconventional high temperature superconductors [J]. Acta Phys. Sin., 2021, 70(1): 017101
(胡江平. 探索非常规高温超导体 [J]. 物理学报, 2021, 70(1): 017101)
- [22] Li J X. Spin fluctuations and unconventional superconducting pairing [J]. Acta Phys. Sin., 2021, 70(1): 017408
(李建新. 自旋涨落与非常规超导配对 [J]. 物理学报, 2021, 70(1): 017408)
- [23] Nagamatsu J, Nakagawa N, Muranaka T, et al. Superconductivity at 39 K in magnesium diboride [J]. Nature, 2001, 410: 63
- [24] Ashcroft N W. Metallic hydrogen: A high-temperature superconductor? [J]. Phys. Rev. Lett., 1968, 21: 1748
- [25] Ashcroft N W. Hydrogen dominant metallic alloys: High temperature superconductors? [J]. Phys. Rev. Lett., 2004, 92: 187002
- [26] Duan D F, Liu Y X, Tian F B, et al. Pressure-induced metallization of dense $(\text{H}_2\text{S})_2\text{H}_2$ with high- T_c superconductivity [J]. Sci. Rep., 2014, 4: 6968
- [27] Gor'kov L P, Kresin V Z. Pressure and high- T_c superconductivity in sulfur hydrides [J]. Sci. Rep., 2016, 6: 25608
- [28] Drozdov A P, Erements M I, Troyan I A, et al. Conventional super-

- conductivity at 203 Kelvin at high pressures in the sulfur hydride system [J]. *Nature*, 2015, 525: 73
- [29] Liu H Y, Naumov I I, Geballe Z M, et al. Dynamics and superconductivity in compressed lanthanum superhydride [J]. *Phys. Rev. B*, 2018, 98: 100102
- [30] Somayazulu M, Ahart M, Mishra A K, et al. Evidence for superconductivity above 260 K in lanthanum superhydride at megabar pressures [J]. *Phys. Rev. Lett.*, 2019, 122: 027001
- [31] Drozdov A P, Kong P P, Minkov V S, et al. Superconductivity at 250 K in lanthanum hydride under high pressures [J]. *Nature*, 2019, 569: 528
- [32] Eremets M I, Minkov V S, Drozdov A P, et al. High-temperature superconductivity in hydrides: Experimental evidence and details [J]. *J. Supercond. Novel Magn.*, 2022, 35: 965
- [33] Zhang S B, Zhang M, Liu H Y. Superconductive hydrogen-rich compounds under high pressure [J]. *Appl. Phys.*, 2021, 127A: 684
- [34] Troyan I A, Semenok D V, Kvashnin A G, et al. Anomalous high-temperature superconductivity in YH_6 [J]. *Adv. Mater.*, 2021, 33: 2006832
- [35] Snider E, Dasenbrock-Gammon N, McBride R, et al. RETRACTED: Synthesis of yttrium superhydride superconductor with a transition temperature up to 262 K by catalytic hydrogenation at high pressures [J]. *Phys. Rev. Lett.*, 2021, 126: 117003
- [36] Semenok D V, Kvashnin A G, Ivanova A G, et al. Synthesis of ThH_4 , ThH_6 , ThH_9 and ThH_{10} : A route to room-temperature superconductivity [DB/OL]. arXiv: 1902.10206, 2019
- [37] Semenok D V, Kvashnin A G, Ivanova A G, et al. Superconductivity at 161 K in thorium hydride ThH_{10} : Synthesis and properties [J]. *Mater. Today*, 2020, 33: 36
- [38] Li B, Miao Z L, Ti L, et al. Predicted high-temperature superconductivity in cerium hydrides at high pressures [J]. *J. Appl. Phys.*, 2019, 126: 235901
- [39] Chen W H, Semenok D V, Huang X L, et al. High-temperature superconducting phases in cerium superhydride with a T_c up to 115 K below a pressure of 1 megabar [J]. *Phys. Rev. Lett.*, 2021, 127: 117001
- [40] Wang H, Tse J S, Tanaka K, et al. Superconductive sodalite-like clathrate calcium hydride at high pressures [J]. *Proc. Natl. Acad. Sci. USA*, 2012, 109: 6463
- [41] Li Z W, He X, Zhang C L, et al. Superconductivity above 200 K discovered in superhydrides of calcium [J]. *Nat. Commun.*, 2022, 13: 2863
- [42] Flores-Livas J A, Boeri L, Sanna A, et al. A perspective on conventional high-temperature superconductors at high pressure: Methods and materials [J]. *Phys. Rep.*, 2020, 856: 1
- [43] Sun Y, Lv J, Xie Y, et al. Route to a superconducting phase above room temperature in electron-doped hydride compounds under high pressure [J]. *Phys. Rev. Lett.*, 2019, 123: 097001
- [44] Di Cataldo S, Von Der Linden W, Boeri L. Phase diagram and superconductivity of calcium borohydrides at extreme pressures [J]. *Phys. Rev.*, 2020, 102B: 014516
- [45] Geng N S, Bi T G, Zurek E. Structural diversity and superconductivity in S-P-H ternary hydrides under pressure [J]. *J. Phys. Chem.*, 2022, 126C: 7208
- [46] Grockowiak A D, Ahart M, Helm T, et al. Hot hydride superconductivity above 550 K [J]. *Front. Electron. Mater.*, 2022, 2: 837651
- [47] Di Cataldo S, Boeri L. Metal borohydrides as ambient-pressure high- T_c superconductors [J]. *Phys. Rev.*, 2023, 107B: L060501
- [48] Song P, Hou Z F, Baptista De Castro P, et al. High-pressure Mg-Sc-H phase diagram and its superconductivity from first-principles calculations [J]. *J. Phys. Chem.*, 2022, 126C: 2747
- [49] Shutov G M, Semenok D V, Kruglov I A, et al. Ternary superconducting hydrides in the La-Mg-H system [J]. *Mater. Today Phys.*, 2024, 40: 101300
- [50] Chen W H, Huang X L, Semenok D V, et al. Enhancement of superconducting properties in the La-Ce-H system at moderate pressures [J]. *Nat. Commun.*, 2023, 14: 2660
- [51] Zhao W D, Huang X L, Zhang Z H, et al. Superconducting ternary hydrides: Progress and challenges [J]. *Natl. Sci. Rev.*, 2024, 11: nwad307
- [52] Gao M, Yan X W, Lu Z Y, et al. Phonon-mediated high-temperature superconductivity in the ternary borohydride KB_2H_8 under pressure near 12 GPa [J]. *Phys. Rev.*, 2021, 104B: L100504
- [53] Zhang Z H, Cui T, Hutcheon M J, et al. Design principles for high-temperature superconductors with a hydrogen-based alloy backbone at moderate pressure [J]. *Phys. Rev. Lett.*, 2022, 128: 047001
- [54] Song Y G, Bi J K, Nakamoto Y, et al. Stoichiometric ternary superhydride LaBeH_8 as a new template for high-temperature superconductivity at 110 K under 80 GPa [J]. *Phys. Rev. Lett.*, 2023, 130: 266001
- [55] Zhao W D, Duan D F, Du M Y, et al. Pressure-induced high- T_c superconductivity in the ternary clathrate system Y-Ca-H [J]. *Phys. Rev.*, 2022, 106B: 014521
- [56] Du M Y, Song H, Zhang Z H, et al. Room-temperature superconductivity in Yb/Lu substituted clathrate hexahydrides under moderate pressure [J]. *Research*, 2022, 2022: 9784309
- [57] Sanna A, Cerqueira T F T, Fang Y W, et al. Prediction of ambient pressure conventional superconductivity above 80 K in hydride compounds [J]. *npj Comput. Mater.*, 2024, 10: 44
- [58] Dolui K, Conway L J, Heil C, et al. Feasible route to high-temperature ambient-pressure hydride superconductivity [J]. *Phys. Rev. Lett.*, 2024, 132: 166001
- [59] Belli F, Novoa T, Contreras-García J, et al. Strong correlation between electronic bonding network and critical temperature in hydrogen-based superconductors [J]. *Nat. Commun.*, 2021, 12: 5381
- [60] Liu L L, Peng F, Song P, et al. Generic rules for achieving room-temperature superconductivity in ternary hydrides with clathrate structures [J]. *Phys. Rev.*, 2023, 107B: L020504
- [61] Marsiglio F. Eliashberg theory: A short review [J]. *Ann. Phys.*, 2020, 417: 168102
- [62] Eliashberg G M. Interactions between electrons and lattice vibrations in a superconductor [J]. *Sov. Phys. JETP*, 1960, 11: 696
- [63] Dynes R C. McMillan's equation and the T_c of superconductors [J]. *Solid State Commun.*, 1972, 10: 615
- [64] Allen P B, Dynes R C. Transition temperature of strong-coupled superconductors reanalyzed [J]. *Phys. Rev.*, 1975, 12B: 905

- [65] McMillan W L. Transition temperature of strong-coupled superconductors [J]. Phys. Rev., 1968, 167: 331
- [66] Oliveira L N, Gross E K U, Kohn W. Density-functional theory for superconductors [J]. Phys. Rev. Lett., 1988, 60: 2430
- [67] Marques M A L, Lüders M, Lathiotakis N N, et al. *Ab initio* theory of superconductivity. II. Application to elemental metals [J]. Phys. Rev., 2005, 72B: 024546
- [68] Lüders M, Marques M A L, Lathiotakis N N, et al. *Ab initio* theory of superconductivity. I. Density functional formalism and approximate functionals [J]. Phys. Rev., 2005, 72B: 024545
- [69] Choudhary K, Garrity K. Designing high- T_c superconductors with BCS-inspired screening, density functional theory, and deep-learning [J]. npj Comput. Mater., 2022, 8: 244
- [70] Shipley A M, Hutcheon M J, Needs R J, et al. High-throughput discovery of high-temperature conventional superconductors [J]. Phys. Rev., 2021, 104B: 054501
- [71] Saha S, Di Cataldo S, Giannessi F, et al. Mapping superconductivity in high-pressure hydrides: The Superhydra project [J]. Phys. Rev. Mater., 2023, 7: 054806
- [72] Sommer T, Willa R, Schmalian J, et al. 3DSC—A dataset of superconductors including crystal structures [J]. Sci. Data, 2023, 10: 816
- [73] Cerqueira T F T, Sanna A, Marques M A L. Sampling the materials space for conventional superconducting compounds [J]. Adv. Mater., 2024, 36: 2307085
- [74] Stanev V, Oses C, Kusne A G, et al. Machine learning modeling of superconducting critical temperature [J]. npj Comput. Mater., 2018, 4: 29
- [75] Breiman L. Random forests [J]. Mach. Learn., 2001, 45: 5
- [76] MDR. MDR SuperCon Datasheet Ver. 220808 [EB/OL]. (2022-16-12)[DateCite]. <https://mdr.nims.go.jp/concern/datasets/mw22v8634>
- [77] Hutcheon M J, Shipley A M, Needs R J. Predicting novel superconducting hydrides using machine learning approaches [J]. Phys. Rev., 2020, 101B: 144505
- [78] Liu Y, Huang H Y, Yuan J, et al. Upper limit of the transition temperature of superconducting materials [J]. Patterns, 2023, 4: 100841
- [79] Wines D, Choudhary K. Data-driven design of high pressure hydride superconductors using DFT and deep learning [J]. Mater. Futures, 2024, 3: 025602
- [80] Ward L, Dunn A, Faghaninia A, et al. Matminer: An open source toolkit for materials data mining [J]. Comput. Mater. Sci., 2018, 152: 60
- [81] Kresse G, Furthmüller J. Efficient iterative schemes for *ab initio* total-energy calculations using a plane-wave basis set [J]. Phys. Rev., 1996, 54B: 11169
- [82] Kresse G, Hafner J. *Ab initio* molecular dynamics for liquid metals [J]. Phys. Rev., 1993, 47B: 558
- [83] Perdew J P, Burke K, Ernzerhof M. Generalized gradient approximation made simple [J]. Phys. Rev. Lett., 1996, 77: 3865
- [84] Wang V, Xu N, Liu J C, et al. VASPKIT: A user-friendly interface facilitating high-throughput computing and analysis using VASP code [J]. Comput. Phys. Commun., 2021, 267: 108033
- [85] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine learning in python [J]. J. Mach. Learn. Res., 2011, 12: 2825
- [86] Pettifor D G. A chemical scale for crystal-structure maps [J]. Solid State Commun., 1984, 51: 31
- [87] Pettifor D G. The structures of binary compounds. I. Phenomenological structure maps [J]. J. Phys., 1986, 19C: 285
- [88] Villars P, Cenzual K, Daams J, et al. Data-driven atomic environment prediction for binaries using the Mendeleev number: Part 1. Composition AB [J]. J. Alloys Compd., 2004, 367: 167
- [89] Liu H Y, Naumov I I, Hoffmann R, et al. Potential high- T_c superconducting lanthanum and yttrium hydrides at high pressure [J]. Proc. Natl. Acad. Sci. USA, 2017, 114: 6990

(责任编辑:李海兰)